

Roteiro de Slides — Quantum Commerce: Análise de Sentimento em Reviews

Roteiro para a apresentação. Cada bloco é um slide: título, tópicos para o slide e notas do apresentador (o que falar). Sugestão: 10–12 slides, ~10 min.

Slide 1 — Capa

- **Quantum Commerce — Análise de Sentimento em Reviews**
- AI Foundation and Learning Models — FIAP MBA
- Integrantes / data

Notas: apresentar o tema em uma frase: "transformar avaliações de clientes em um termômetro automático de satisfação".

Slide 2 — O problema

- Quantum Commerce: varejo omnicanal, 12 países, +5 milhões de SKUs
- "Muro da escalabilidade operacional": suporte e leitura de mercado no manual não escalam
- Milhares de reviews por dia — informação valiosa presa no texto

Notas: contextualizar o cenário do enunciado; ninguém lê tudo manualmente.

Slide 3 — O desafio escolhido

- Entre os desafios do enunciado: **análise de sentimento em reviews**
- Objetivo: classificar cada avaliação como **positiva** ou **negativa**
- Valor: priorizar suporte, detectar problemas cedo, métrica contínua de satisfação

Notas: deixar claro o "para quê" antes do "como".

Slide 4 — Os dados

- Dataset **Amazon Review Polarity** (negativo = 1, positivo = 2), balanceado
- 3,6 M treino / 400 mil teste → usamos **amostra estratificada de 50k / 10k**
- Por quê: demonstrar a solução em CPU, em minutos, sem perder representatividade

Notas: justificar a amostra — é decisão de engenharia, não preguiça.

Slide 5 — Caminhos possíveis (comparação)

Abordagem	Captura	Limitação
TF-IDF + SVM	importância de termos	ignora a ordem das palavras
word2vec + SVM	semântica das palavras	a média perde a ordem
LSTM	a review como sequência	treino mais lento
BERT / Transformers	contexto profundo	caro, exige GPU

Notas: este slide atende ao item 2 do enunciado (comparar alternativas).

Slide 6 — Por que LSTM

- O que diferencia: **ordem das palavras** ("not good" $\neq$ "good")
- LSTM tem **memória de contexto** — entende negação e construções
- Equilíbrio: mais capacidade que os clássicos, mais barata que o BERT
- É a arquitetura de sentimento estudada nas aulas

Notas: a escolha é equilíbrio capacidade $\times$ custo $\times$ aderência à disciplina.

Slide 7 — Pipeline da solução

1. Amostragem → 2. Pré-processamento → 3. word2vec → 4. Treino LSTM → 5. Avaliação → 6. Inferência - Vocabulário construído **só com o treino** (sem vazamento) - Sequências padronizadas em 200 tokens

Notas: mostrar que é um fluxo reproduzível, script a script.

Slide 8 — A arquitetura

- Embedding(200) → LSTM(128, 2 camadas) → Dropout → Linear → Sigmoid
- Embeddings **inicializados com word2vec** treinado no próprio corpus
- word2vec aprendeu semântica real:
- terrible $\approx$ horrible, awful · great $\approx$ terrific, fantastic

Notas: o word2vec sozinho já valida que o modelo "entende" as palavras.

Slide 9 — Resultados

Modelo	Acurácia	F1
TF-IDF + SVM (baseline)	0,886	0,886
LSTM (word2vec)	0,895	0,895

- Matriz de confusão da LSTM (figura `figures/matriz_confusao_lstm.png`)

Notas: a LSTM (89,5%) supera o baseline SVM (88,6%). Reforçar que o melhor modelo foi salvo via checkpoint na 2ª época — depois disso a validação piora (overfitting). Mostrar a matriz de confusão (acertos na diagonal).

Slide 10 — Demo: classificando reviews novas

```
[POSITIVO] p=0.99  "This product is amazing, exactly what I needed..."  
[NEGATIVO] p=0.01  "Terrible quality, it broke after one day..."  
[POSITIVO] p=0.73  "It works fine, nothing special but it does the job."
```

- O modelo devolve **rótulo + probabilidade** para qualquer texto novo

Notas: se possível, rodar `python 07_inferencia.py "..."` ao vivo.

Slide 11 — Limitações e riscos

- Treinado em **inglês**; pt-BR exige novos dados/embeddings
- Apenas **binário** (sem neutro); ironia ainda é difícil
- **Mudança de domínio**: re-treinar com dados da Quantum
- Vocabulário fixo → re-treino periódico; atenção a **viés**

Notas: honestidade sobre limites fortalece a proposta.

Slide 12 — Impacto e evolução

- Termômetro de satisfação automático e em escala
- Menos churn, resposta mais rápida, insumo para recomendação/catálogo
- Evolução: fine-tuning de transformer; multi-classe (1-5 estrelas); análise por aspecto
- **Conclusão:** solução viável, fundamentada e pronta para evoluir

Notas: fechar amarrando no valor de negócio do Slide 3.